



Université Internationale de Rabat
Ecole Supérieure d'informatique et du numérique
Département de Cybersécurité

PHISHGUARD AI

Application Intelligente de Détection et d'Analyse d'Emails de Phishing

Réalisé par :

Imane Habbani

Abir EL Hanafi

Encadré par :

Mr.Hamza Gamouh

Année académique 2025-202

Table des matières

Résumé Exécutif	3
1 Introduction et Contexte	4
2 Problématique	Error! Bookmark not defined.
3 Objectifs du Projet	5
4 Présentation de la Solution	6
5 Architecture Technique	7
5.1 Choix Architectural : Approche Stateless	7
5.2 Stack Technologique	7
5.3 Flux de Données	8
6 Intégration de l'Intelligence Artificielle	10
6.1 Moteur d'Analyse NLP	10
6.2 Logique de Classification	11
7 Analyse des Résultats et Cas d'Usage	12
8 Sécurité et Confidentialité	14
9 Limites et Contraintes	14
10 Perspectives d'Évolution	15
11 Conclusion	16

Résumé Exécutif

Le phishing constitue aujourd'hui l'une des menaces les plus répandues en cybersécurité, reposant sur des techniques d'ingénierie sociale visant à tromper les utilisateurs afin d'obtenir des informations sensibles. Ces attaques exploitent la confiance humaine et sont souvent difficiles à détecter, notamment lorsque les emails frauduleux imitent fidèlement des communications légitimes.

Pour répondre à cette problématique, ce projet propose **PhishGuard AI**, une application web dédiée à l'analyse automatique des emails suspects à l'aide de l'intelligence artificielle. L'application permet à l'utilisateur de soumettre le sujet et le contenu d'un email, lesquels sont analysés par un modèle d'intelligence artificielle spécialisé dans le traitement du langage naturel.

La solution repose sur une architecture frontend développée avec **React**, assurant une interface utilisateur dynamique et intuitive, et sur un modèle d'intelligence artificielle hébergé sur la plateforme **Hugging Face** pour l'analyse sémantique du contenu des emails. Cette combinaison permet de séparer clairement l'interaction utilisateur de la logique d'analyse intelligente.

À l'issue du traitement, l'application fournit un résultat clair sous la forme d'une **classification de l'email (Safe ou Suspicious)**, accompagnée d'un score de risque et de recommandations de sécurité. Conçue selon une approche respectueuse de la confidentialité, PhishGuard AI ne stocke aucune donnée utilisateur et vise à offrir un outil à la fois technologique et pédagogique pour sensibiliser les utilisateurs aux risques liés au phishing.

Objectif pédagogique

Au-delà de la détection automatique des emails de phishing, PhishGuard AI s'inscrit dans une démarche pédagogique visant à renforcer la sensibilisation des utilisateurs aux risques liés à la cybersécurité. L'objectif n'est pas uniquement de fournir une décision binaire, mais également d'accompagner l'utilisateur dans la compréhension des mécanismes utilisés par les attaquants.

L'application permet à l'utilisateur de soumettre le contenu d'un email et d'obtenir, en retour, un score de risque, un niveau de dangerosité ainsi qu'une liste d'indicateurs expliquant les raisons de la classification. Ces éléments sont complétés par des recommandations de sécurité concrètes, telles que la vérification de l'expéditeur ou l'évitement des liens suspects.

En adoptant cette approche explicative, PhishGuard AI encourage l'utilisateur à développer un esprit critique face aux communications électroniques et à adopter de meilleures pratiques de sécurité. Cette dimension pédagogique constitue un aspect central du projet, en complément de l'utilisation de l'intelligence artificielle, et contribue à faire de l'application un outil d'aide à la décision accessible et formateur, tout en respectant la confidentialité des données analysées.

1 Introduction et Contexte

Avec la transformation numérique des organisations et la généralisation du courrier électronique comme moyen de communication principal, les attaques de phishing se sont imposées comme l'une des menaces les plus répandues en cybersécurité. Ces attaques consistent à tromper les utilisateurs en se faisant passer pour des entités légitimes afin d'obtenir des informations sensibles, telles que des identifiants, des données personnelles ou bancaires.

La fréquence et la sophistication des attaques de phishing ont considérablement augmenté ces dernières années. Les messages frauduleux sont désormais rédigés de manière crédible, utilisent un langage professionnel et exploitent des techniques d'ingénierie sociale basées sur l'urgence, la peur ou la confiance. Cette évolution rend la détection particulièrement difficile pour les utilisateurs non experts, qui peuvent confondre un email frauduleux avec une communication officielle.

Les mécanismes de protection traditionnels, tels que les filtres anti-spam et les règles statiques, montrent certaines limites face à ces nouvelles formes d'attaques, notamment lorsqu'elles reposent uniquement sur la manipulation psychologique plutôt que sur des logiciels malveillants. Dans ce contexte, l'intelligence artificielle, et plus particulièrement les modèles de traitement du langage naturel, offre des perspectives prometteuses pour analyser le contenu textuel des emails de manière plus contextuelle et adaptative.

C'est dans ce cadre que s'inscrit le projet **PhishGuard AI**, développé dans un contexte académique. L'objectif du projet est d'explorer l'utilisation de l'intelligence artificielle appliquée à la cybersécurité à travers la conception d'une application web capable d'analyser automatiquement des emails et d'aider les utilisateurs à évaluer les risques de phishing. Ce projet permet ainsi de mettre en pratique des compétences en développement web et en intelligence artificielle tout en répondant à une problématique concrète et actuelle.

1 Problématique

Les attaques de phishing représentent un défi majeur en cybersécurité en raison de leur capacité à exploiter les faiblesses humaines plutôt que des vulnérabilités techniques. Contrairement aux attaques basées sur des logiciels malveillants, le phishing repose sur des techniques d'ingénierie sociale visant à tromper l'utilisateur en se faisant passer pour une entité de confiance.

La détection des emails de phishing est particulièrement complexe car ces messages sont souvent rédigés dans un langage crédible et professionnel, imitant fidèlement les communications officielles d'organisations légitimes. Les attaquants utilisent fréquemment des stratégies psychologiques telles que l'urgence, la peur ou la menace afin de pousser l'utilisateur à agir rapidement sans analyser le contenu de manière critique.

Les mécanismes de protection traditionnels, tels que les filtres anti-spam et les systèmes basés sur des règles statiques ou des listes noires, montrent leurs limites face à ces attaques évolutives et contextuelles. Ces solutions peinent notamment à détecter des messages nouvellement conçus ou personnalisés, qui ne correspondent pas à des signatures connues.

Par ailleurs, les utilisateurs non experts disposent rarement d'outils leur permettant de comprendre pourquoi un email est considéré comme suspect. L'absence d'explications claires favorise des comportements à risque, comme le clic sur des liens frauduleux ou la transmission d'informations sensibles.

Dans ce contexte, la problématique centrale de ce projet est la suivante :

\textit{Comment aider un utilisateur non expert à évaluer le risque d'un email avant toute interaction, tout en lui fournissant des éléments explicatifs et pédagogiques favorisant une meilleure compréhension des menaces de phishing ?}

2 Objectifs du Projet

L'objectif principal de ce projet est de concevoir une application web capable de détecter automatiquement les emails suspects à l'aide de l'intelligence artificielle, afin d'aider les utilisateurs à identifier les tentatives de phishing avant toute interaction potentiellement dangereuse.

En complément de cet objectif principal, plusieurs objectifs secondaires ont été définis afin d'enrichir la solution et d'en renforcer la pertinence :

- Fournir un score de risque numérique permettant de quantifier le niveau de danger associé à un email analysé.
- Expliquer la décision prise par le système à travers des indicateurs explicites mettant en évidence les éléments suspects détectés dans le contenu du message.
- Sensibiliser l'utilisateur aux techniques de phishing en lui proposant des recommandations de sécurité adaptées, favorisant ainsi l'adoption de bonnes pratiques.
- Garantir la confidentialité des données analysées en adoptant une architecture sans stockage persistant, conformément au principe de \textit{Privacy by Design}.

Ces objectifs s'inscrivent dans une démarche à la fois technique et pédagogique, visant à proposer un outil d'aide à la décision accessible, fiable et respectueux de la vie privée des utilisateurs.


3 Présentation de la Solution

PhishGuard AI se présente sous la forme d'une application web accessible via un navigateur, sans nécessiter d'installation préalable. L'interface a été conçue dans un objectif de simplicité et de clarté afin de permettre une prise en main rapide, y compris par des utilisateurs non experts en cybersécurité.

L'application propose un formulaire de saisie composé de deux champs principaux : le sujet de l'email et le contenu du message. L'utilisateur peut copier-coller l'email qu'il souhaite analyser directement dans l'interface. Un bouton dédié permet ensuite de lancer l'analyse de manière instantanée.

Une fois l'analyse terminée, les résultats sont affichés de façon claire et structurée. L'utilisateur visualise immédiatement la classification de l'email (Safe ou Suspicious), accompagnée d'un score de risque et d'un niveau de dangerosité. Des indicateurs explicatifs ainsi que des recommandations de sécurité sont également présentés afin d'aider l'utilisateur à comprendre la décision prise par le système.

L'interface inclut également un mode de démonstration permettant de pré-remplir les champs avec un exemple d'email frauduleux. Cette fonctionnalité facilite la compréhension du fonctionnement de l'application et permet d'illustrer rapidement ses capacités lors de tests ou de présentations. Dans l'ensemble, PhishGuard AI met l'accent sur une expérience utilisateur fluide, intuitive et orientée vers l'aide à la décision.



The screenshot displays the PhishGuard AI web application interface. At the top left is the PhishGuard AI logo with the tagline 'Intelligent Email Threat Detection'. At the top right are links for 'How it Works' and 'Privacy'. The main heading is 'Is that email safe?'. Below this, a sub-header states: 'Phishing attacks are getting smarter. Use our AI-powered detector to analyze suspicious emails, understand the risks, and learn how to stay safe.' The central part of the interface is a light blue box titled 'Analyze Email' with a magnifying glass icon. It contains the instruction 'Paste the subject and body of a suspicious email below.' followed by a link 'Try an example'. There are two input fields: 'Subject Line' with a placeholder 'e.g., URGENT: Action Required' and 'Email Body' with a placeholder 'Paste the full content of the email here...'. The interface is clean and modern, using a light blue and white color scheme.

4 Architecture Technique

4.1 Choix Architectural : Approche Stateless

PhishGuard AI repose sur une architecture frontend stateless, dans laquelle l'ensemble de l'application est exécuté côté client, au sein du navigateur de l'utilisateur. L'interface web, développée avec React, assure la collecte des données saisies par l'utilisateur ainsi que l'affichage des résultats de l'analyse.

Contrairement à une architecture client-serveur classique, cette solution ne fait appel à aucun serveur backend applicatif dédié ni à une base de données pour le stockage des informations. L'application communique directement avec un service d'intelligence artificielle externe, accessible via la plateforme Hugging Face, afin de réaliser l'analyse du contenu des emails.

Ce choix architectural permet de simplifier le déploiement du système tout en renforçant la confidentialité des données. Les emails soumis par l'utilisateur sont traités de manière éphémère et ne sont jamais stockés de façon persistante. L'absence de backend applicatif réduit également la surface d'attaque du système et limite les risques liés à la gestion de données sensibles.

Ainsi, l'architecture frontend stateless adoptée dans PhishGuard AI est pleinement cohérente avec les objectifs du projet, en particulier ceux liés à la protection de la vie privée, à la simplicité d'utilisation et au caractère pédagogique de l'application.

4.2 Stack Technologique

L'architecture de PhishGuard AI repose sur un flux de données simple et linéaire, garantissant à la fois la clarté du fonctionnement et la confidentialité des informations traitées. Le processus d'analyse peut être décrit selon les étapes suivantes :

Dans un premier temps, l'utilisateur interagit avec l'application via l'interface web développée en React. Il saisit le sujet et le contenu de l'email qu'il souhaite analyser à l'aide du composant dédié à la collecte des données.

Ces informations sont ensuite transmises au service d'analyse d'intelligence artificielle intégré au frontend, implémenté dans le fichier `geminiService.ts`. Ce service est responsable de la préparation des données, de la construction du prompt et de la gestion de l'appel au modèle d'intelligence artificielle externe.

Le service d'analyse communique directement avec l'API d'inférence de la plateforme Hugging Face, qui héberge un modèle de langage pré-entraîné (Mistral 7B). Le modèle traite le contenu textuel de l'email afin d'identifier des indices de phishing et génère une réponse structurée.

Enfin, le résultat de l'analyse, comprenant un score de risque, un niveau de dangerosité ainsi que des recommandations de sécurité, est renvoyé à l'interface React. Ces informations sont alors interprétées et affichées de manière claire et compréhensible à l'utilisateur.

Ce flux, allant de l'utilisateur jusqu'au modèle d'intelligence artificielle puis au retour des résultats, illustre une architecture simple, efficace et entièrement orientée vers l'analyse en temps réel, sans stockage persistant des données.

4.3 Flux de Données

Le frontend de PhishGuard AI constitue la couche d'interaction entre l'utilisateur et le système. Il est développé à l'aide de technologies web modernes, choisies pour leur robustesse, leur maintenabilité et leur capacité à offrir une expérience utilisateur fluide.

L'interface utilisateur est construite avec le framework **React**, qui permet une organisation modulaire de l'application à travers des composants réutilisables. L'utilisation de **TypeScript** renforce la fiabilité du code en assurant un typage statique des données échangées entre les différents composants, réduisant ainsi les risques d'erreurs à l'exécution. Le style et la mise en page sont gérés à l'aide de **Tailwind CSS**, offrant un design moderne, cohérent et responsive.

Le rôle principal du frontend est de collecter les données saisies par l'utilisateur, à savoir le sujet et le contenu de l'email à analyser, puis de transmettre ces informations au service d'analyse d'intelligence artificielle. Une fois l'analyse terminée, le frontend est également chargé d'interpréter la réponse reçue et d'afficher les résultats de manière claire et structurée, incluant la classification de l'email, le score de risque, les indicateurs détectés et les recommandations de sécurité.

Il est important de souligner que le frontend ne réalise aucun calcul intelligent ni aucune prise de décision concernant la classification des emails. Il ne fait qu'orchestrer l'interaction utilisateur et la restitution des résultats fournis par le service d'analyse IA. Cette séparation claire des responsabilités contribue à la simplicité, à la maintenabilité et à la cohérence globale de l'architecture du système.

4.4 Service d'analyse d'Intelligence Artificielle

Le cœur analytique de PhishGuard AI est implémenté dans un service dédié à l'analyse par intelligence artificielle, situé dans le fichier `\textit{geminiService.ts}`. Ce service centralise l'ensemble de la logique liée à l'interaction avec le modèle d'intelligence artificielle et constitue l'élément clé du système de détection.

Le service a pour rôle principal de préparer et d'envoyer une requête vers un modèle de langage public hébergé sur la plateforme Hugging Face. À partir du sujet et du contenu de l'email fournis par l'utilisateur, un prompt structuré est généré. Ce prompt décrit explicitement la tâche attendue du modèle, à savoir l'analyse du message et la génération d'un résultat structuré incluant une classification, un score de risque, un niveau de dangerosité, des indicateurs et des recommandations.

La réponse retournée par le modèle est attendue sous la forme d'un objet JSON. Le service d'analyse se charge de parser cette réponse et de vérifier la présence des différents champs afin de garantir la cohérence des données transmises au frontend. Cette approche permet de standardiser la communication entre le modèle d'intelligence artificielle et l'interface utilisateur.

Afin d'assurer la robustesse du système, plusieurs mécanismes de sécurisation ont été mis en place. En cas d'erreur lors de l'appel à l'API externe, de réponse invalide ou d'indisponibilité du service d'intelligence artificielle, un mécanisme de secours basé sur des règles heuristiques simples est déclenché. Ce mécanisme permet de fournir une analyse minimale sans interrompre le fonctionnement de l'application, évitant ainsi tout comportement imprévu ou affichage d'erreur pour l'utilisateur.

Ce service d'analyse IA joue donc un rôle central dans l'architecture de PhishGuard AI, en encapsulant toute la logique intelligente du système et en garantissant une interaction fiable et sécurisée avec le modèle d'intelligence artificielle externe.

5 Intégration de l'Intelligence Artificielle

5.1 Moteur d'Analyse NLP

L'analyse des emails dans PhishGuard AI repose sur l'utilisation d'un modèle de langage de grande taille (\textit{Large Language Model – LLM}), spécialisé dans la compréhension et l'analyse de contenus textuels. Ce type de modèle est particulièrement adapté aux problématiques de phishing, dans la mesure où ces attaques reposent essentiellement sur le langage, le ton et le contexte des messages.

Le modèle utilisé est hébergé sur la plateforme Hugging Face et est accessible via une API d'inférence publique. Cette plateforme permet d'exploiter des modèles pré-entraînés capables de traiter des textes complexes sans nécessiter d'entraînement préalable spécifique dans le cadre du projet.

Le rôle principal du modèle est d'analyser le contenu sémantique de l'email soumis par l'utilisateur. À partir du sujet et du corps du message, le modèle identifie des patterns linguistiques et contextuels typiquement associés aux tentatives de phishing, tels que l'urgence artificielle, les demandes d'informations sensibles, ou les formulations destinées à manipuler le comportement de l'utilisateur.

L'utilisation d'un modèle de langage permet ainsi de dépasser une simple détection par mots-clés, en offrant une analyse plus fine et contextuelle du texte. Cette approche constitue un élément central de l'efficacité de PhishGuard AI dans la détection des emails suspects.

5.2 Logique de Classification

Dans PhishGuard AI, l'évaluation du niveau de danger d'un email repose sur la génération d'un score de risque numérique produit par le modèle d'intelligence artificielle. Ce score représente une estimation du degré de suspicion associé au message analysé, en fonction de son contenu sémantique et des patterns linguistiques détectés.

Le modèle d'intelligence artificielle, interrogé via l'API d'inférence Hugging Face, analyse le sujet et le corps de l'email et retourne un résultat structuré comprenant notamment un score de risque compris entre 0 et 100. Ce score est calculé par le modèle lui-même et reflète la probabilité qu'un email corresponde à une tentative de phishing.

Afin de garantir la robustesse du système, un mécanisme de secours (fallback) est mis en place au niveau du service d'analyse IA. En cas d'erreur lors de l'appel au modèle externe, de réponse invalide ou d'indisponibilité du service, une analyse locale basée sur des règles heuristiques simples est déclenchée. Cette analyse de secours permet de générer un score approximatif et d'éviter toute interruption du fonctionnement de l'application.

Le niveau de risque affiché à l'utilisateur est ensuite dérivé du score numérique. Trois niveaux de dangerosité sont définis :

- **LOW** pour un score faible, indiquant un risque limité,
- **MEDIUM** pour un score intermédiaire, signalant des éléments suspects,
- **HIGH** pour un score élevé, correspondant à une forte probabilité de phishing.

Cette approche permet de fournir à l'utilisateur une évaluation à la fois quantitative et qualitative du risque, tout en assurant une continuité de service même en cas de défaillance du modèle d'intelligence artificielle.

6 Analyse des Résultats et Cas d'Usage


Afin d'évaluer le bon fonctionnement de PhishGuard AI, plusieurs tests ont été réalisés sur des emails de nature différente. Cette section présente deux cas d'utilisation représentatifs : un email de phishing simulé et un email institutionnel légitime. Les résultats obtenus illustrent la capacité de l'application à distinguer efficacement les messages suspects des communications authentiques.

6.1 Cas 1 – Email de phishing (Suspicious)

Le premier cas d'utilisation concerne un email frauduleux simulé, utilisé à des fins de démonstration. Ce message contient plusieurs caractéristiques typiques des attaques de phishing, notamment un langage d'urgence, une menace explicite et un lien incitant l'utilisateur à agir rapidement.

Après soumission de l'email via l'interface de l'application (Figure X), l'analyse produite par PhishGuard AI classe le message comme *Suspicious*. Le score de risque généré est élevé (environ 70/100), indiquant une forte probabilité de tentative de phishing. Le niveau de dangerosité associé est **HIGH**.

Les indicateurs détectés mettent en évidence des éléments tels que l'urgence artificielle, la présence d'un lien suspect et la demande implicite d'informations sensibles. Des recommandations de sécurité sont également affichées afin de guider l'utilisateur dans les actions à entreprendre, comme éviter de cliquer sur les liens et vérifier l'identité de l'expéditeur.




6.2 Cas 2 – Email institutionnel légitime (Safe)

Le second cas d'utilisation concerne un email institutionnel légitime, issu du contexte universitaire. Ce message présente un ton neutre et informatif, ne contient aucune menace, ni lien suspect, ni demande d'informations sensibles.

L'analyse réalisée par PhishGuard AI classe cet email comme *Safe*. Le score de risque obtenu est faible (environ 10/100), correspondant à un niveau de dangerosité **LOW**. Aucun indicateur suspect significatif n'est détecté, ce qui confirme la légitimité du message analysé.

Ce cas démontre la capacité du système à ne pas générer de faux positifs excessifs lorsqu'il est confronté à des communications authentiques et professionnelles.



6.3 Analyse comparative des résultats

La comparaison entre ces deux cas d'utilisation met en évidence la pertinence de l'approche adoptée. PhishGuard AI parvient à différencier efficacement un email frauduleux d'un email légitime en s'appuyant sur l'analyse sémantique du contenu, tout en fournissant des résultats clairs, explicatifs et compréhensibles pour l'utilisateur.

Ces résultats confirment la capacité de l'application à remplir ses objectifs de détection, de sensibilisation et d'aide à la décision dans un contexte réel d'utilisation.

7 Sécurité et Confidentialité

La sécurité et la confidentialité des données constituent des aspects fondamentaux du projet PhishGuard AI, compte tenu de la nature potentiellement sensible des emails analysés. Dès la conception du système, une approche axée sur le respect de la vie privée a été adoptée.

L'application repose sur une architecture sans base de données et ne met en œuvre aucun mécanisme de stockage persistant des informations soumises par les utilisateurs. Les emails analysés ne sont ni sauvegardés, ni enregistrés, ni historisés sous quelque forme que ce soit. Cette absence volontaire de stockage réduit considérablement les risques de fuite de données ou d'exploitation malveillante en cas de compromission du système.

Le traitement des données est strictement éphémère. Le contenu de l'email est utilisé uniquement le temps nécessaire à l'analyse par le service d'intelligence artificielle, puis il est immédiatement perdu après la génération et l'affichage du résultat. Aucune donnée n'est conservée au-delà de cette étape.

En adoptant cette approche stateless, PhishGuard AI respecte les principes de minimisation des données et de `\textit{Privacy by Design}`. Cette conception permet de garantir un haut niveau de confidentialité pour l'utilisateur, tout en assurant une analyse efficace et transparente des emails soumis.

8 Limites et Contraintes

Bien que PhishGuard AI réponde efficacement aux objectifs fixés, certaines limites doivent être prises en considération, notamment en raison des choix techniques et conceptuels adoptés dans le cadre de ce projet.

Tout d'abord, l'application dépend d'une connexion Internet active, dans la mesure où l'analyse des emails repose sur l'appel à un modèle d'intelligence artificielle hébergé sur une plateforme externe. En cas d'indisponibilité du réseau ou du service d'inférence, les capacités d'analyse peuvent être réduites, bien qu'un mécanisme de secours local soit prévu pour assurer une continuité minimale.

Par ailleurs, le modèle utilisé est un modèle pré-entraîné générique, qui n'a pas été spécifiquement affiné (`\textit{fine-tuned}`) sur un ensemble de données dédié au phishing. Cette absence de spécialisation peut entraîner des imprécisions dans certains cas particuliers, notamment lorsque les emails analysés présentent des formulations ambiguës ou atypiques. Comme toute solution basée sur l'intelligence artificielle, PhishGuard AI est également susceptible de produire des faux positifs ou des faux négatifs. Un email légitime rédigé de manière inhabituelle peut être considéré comme suspect, tandis qu'un message frauduleux particulièrement bien conçu peut ne pas être détecté avec certitude.

Enfin, l'analyse repose exclusivement sur le contenu textuel fourni par l'utilisateur. Les métadonnées techniques des emails (telles que les en-têtes SMTP, les mécanismes SPF, DKIM ou DMARC) ne sont pas prises en compte, ce qui limite la profondeur de l'analyse dans certains scénarios.

Ces limites n'affectent pas la validité du projet, mais soulignent les axes d'amélioration possibles pour une évolution vers une solution plus robuste et plus complète.

9 Perspectives d'Évolution

Bien que PhishGuard AI remplisse les objectifs fixés dans le cadre de ce projet, plusieurs axes d'amélioration peuvent être envisagés afin d'en faire une solution plus complète et plus robuste.

Une première évolution consisterait à l'ajout d'un backend sécurisé jouant le rôle d'intermédiaire entre le frontend et le service d'intelligence artificielle. Un tel composant permettrait de mieux gérer les clés d'API, de contrôler les accès, de limiter les abus et d'améliorer la sécurité globale de l'application, tout en conservant une approche respectueuse de la confidentialité.

Une autre perspective importante serait l'implémentation d'un mécanisme de \textit{Retrieval-Augmented Generation} (RAG). Ce procédé permettrait d'enrichir l'analyse du modèle d'intelligence artificielle en s'appuyant sur une base de connaissances externe, par exemple des exemples d'emails de phishing connus, des règles de sécurité ou des recommandations officielles. L'intégration d'un RAG améliorerait la précision et la contextualisation des résultats fournis.

Par ailleurs, l'entraînement ou l'affinage (\textit{fine-tuning}) d'un modèle spécifiquement dédié à la détection de phishing constituerait une amélioration significative. Un modèle entraîné sur un jeu de données spécialisé, notamment dans un contexte linguistique précis, permettrait de réduire les faux positifs et d'augmenter la fiabilité des analyses.

D'autres évolutions pourraient inclure la mise en place d'un historique utilisateur optionnel, permettant de consulter les analyses précédentes, sous réserve de garanties strictes en matière de confidentialité. Enfin, l'extension de l'application à d'autres canaux de communication, tels que les SMS (\textit{smishing}) ou les plateformes de messagerie instantanée comme WhatsApp, permettrait d'élargir le champ d'application de PhishGuard AI face à des menaces toujours plus diversifiées.

10 Conclusion

Ce projet a permis de concevoir et de développer **PhishGuard AI**, une application web dédiée à la détection et à l'analyse des emails de phishing à l'aide de l'intelligence artificielle. Face à l'augmentation constante des attaques basées sur l'ingénierie sociale, l'objectif principal était de proposer un outil capable d'aider les utilisateurs à évaluer le risque associé à un email avant toute interaction.

Les objectifs fixés en début de projet ont été atteints. L'application est fonctionnelle et permet d'analyser le contenu d'un email afin de fournir une classification claire (*Safe* ou *Suspicious*), un score de risque, un niveau de dangerosité ainsi que des recommandations de sécurité explicatives. L'architecture frontend stateless adoptée garantit une utilisation simple et respectueuse de la confidentialité des données, sans stockage persistant des informations analysées.

Sur le plan pédagogique et technique, ce projet a constitué une expérience enrichissante, permettant de mettre en pratique des compétences en développement web moderne, en intégration d'intelligence artificielle et en cybersécurité. Il a également permis de mieux comprendre les enjeux liés à l'utilisation de modèles de langage pour l'analyse de contenus sensibles, ainsi que les limites associées à ces technologies.

Enfin, PhishGuard AI se présente comme un projet évolutif. De nombreuses perspectives d'amélioration ont été identifiées, telles que l'ajout d'un backend sécurisé, l'intégration de mécanismes avancés comme le RAG, ou encore l'extension de l'analyse à d'autres canaux de communication. Ces évolutions pourraient transformer ce prototype académique en une solution plus robuste et adaptée à un usage réel à grande échelle.